KELOMPOK [[NN]] · PROPOSAL M0

Proposal proyek akhir

Cross-modal retrieval pada data budaya Indonesia

KELOMPOK	[[03]] · [[Titut Encoder]]	MATA KULIAH	IF25-40304 · Ganjil 2026/2027
DOSEN PENGAMPU	I Wayan Wiprayoga Wisesa	TAHAP	M0 · Pertemuan 10

1 Rumusan masalah

Bagaimana meningkatkan kinerja pencarian lintas modal gambar–teks untuk *query* berbahasa Indonesia serta memperkecil kesenjangan kinerja (*language gap*) terhadap *query* berbahasa Inggris pada *dataset* SEA-VL Indonesian subset menggunakan *encoder* pra-latih yang dibekukan?

2 Hipotesis

Mengganti encoder teks-gambar *baseline* (clip-ViT-B-32-multilingual-v1) dengan *encoder* multibahasa yang lebih baru (SigLIP 2 Base, NLLB-CLIP-SigLIP) akan menaikkan Recall@1 teks Indonesia ke gambar pada validasi SEA-VL dan memperkecil selisihnya terhadap teks Inggris, karena *encoder baseline* memiliki cakupan bahasa yang lebih sempit. Melatih lapisan proyeksi kecil di atas representasi beku menggunakan data latih diperkirakan memberi kenaikan tambahan, karena proyeksi tersebut belajar menyejajarkan ruang vektor teks Indonesia dan gambar secara langsung dari data domain budaya Indonesia. *Encoder* tetap dibekukan.

3 Metrik

Performa sistem diukur dengan Recall@1, Recall@5, Recall@10, dan mAP@K pada split validasi (275 sampel) untuk empat arah pencarian, yaitu gambar ke teks Indonesia, gambar ke teks Inggris, teks Indonesia ke gambar, dan teks Inggris ke gambar. *Language gap* diukur sebagai selisih Recall@1 antara query Inggris dan Indonesia pada arah yang sama. Kenaikan didefinisikan sebagai selisih yang interval kepercayaan 95%-nya (*paired bootstrap*) tidak mencakup nol. Dengan pembanding acak Recall@1 = $1/275 \approx 0{,}36\%$.

4 Rencana pendekatan utama

Tandai satu pendekatan utama (boleh dikombinasikan; boleh berubah setelah M1).

- ☑ (a) mengganti encoder multibahasa (misalnya model berbasis SigLIP atau multilingual CLIP yang lebih baru)
- ☐ (b) prompt ensemble berbahasa Indonesia, termasuk terjemahan dan variasi templat
- ☑ (c) melatih proyeksi/adapter kecil di atas representasi beku
- ☐ (d) reranking dengan cross-encoder pada sejumlah kandidat teratas

☐ (e) augmentasi data dengan terjemahan

Pendekatan utama kelompok adalah (a) mengganti *encoder* multibahasa, dan membandingkan *baseline* M1 dengan SigLIP 2 Base dan NLLB-CLIP-SigLIP. Kedua *encoder* dibekukan, *embedding* dihitung sekali, lalu disimpan ke file. Sebagai kombinasi, kami melatih lapisan proyeksi kecil (linear/MLP) dengan tujuan kontrastif pada train.csv (2.072 sampel) untuk menyejajarkan *embedding* teks Indonesia dan gambar. *Encoder* tetap beku, hanya proyeksi yang dilatih. *Ablation* mengukur efek (a) dan (c) secara terpisah.

5 Pembagian kerja

#	Peran	Nama	Target sampai M2
1	Data dan Etika Data	Ahmad Ali Mukti	Melakukan audit leakage untuk varian eksperimen
2	Baseline dan Pipeline	Bayu Brigas Novaldi	Buat *pipeline* yang membaca data, *encode* gambar dan teks dengan SigLIP 2, simpan *embedding* ke file, lalu *ranking* hasil *retreival*-nya
3	Eksperimen Penyejajaran/Fusi	Anisah Octa Rohila	Menjalankan perbandingan ≥2 varian encoder + proyeksi dan melaporkan tabel ablation Recall@K
4	Evaluasi dan Uji Kasus Sulit	Aryasatya Widyatna Akbar	Melakukan evaluasi Recall@1/5/10 dan mAP@K untuk 4 arah pencarian pada evaluasi, menghitung *language gap,* dan menyusun daftar kasus serta menganalisa penyebab kegagalannya.
5	Integrasi dan Koordinasi	Jesika Filosovi Br P-A	Menyatukan Laporan M1, Menyatukan laporan M2 dan membuat PPT presentasi

6 Reproduksi baseline

Jalankan kembali perhitungan *baseline* dari lembar kerja Pertemuan 09 dan tulis angka Anda sendiri.

Besaran	Angka hasil reproduksi	Seed	Perangkat dan waktu jalan
InfoNCE	Sebelum penyelarasan 10.6138, sesudah penyelarasan 0.1618	42	CPU, 0 detik
Recall@1	Sebelum penyelarasan 1/6 (0.167), sesudah penyelarasan 6/6 (1.000)	42	CPU, 0 detik

Baris yang diminta: *InfoNCE* dan *Recall@1*. Pembanding acak untuk N gambar validasi: *Recall@1* = 1/N.

Angka hasil reproduksi kelompok sama dengan lembar kerja: *InfoNCE* turun dari 10,6138 menjadi 0,1618 dan Recall@1 naik dari 1/6 menjadi 6/6, sehingga tidak ada selisih. Hasil ini identik karena data sintetis dibangkitkan dengan *seed* 42 yang tetap dan perhitungannya deterministik. Perlu dicatat bahwa angka "sesudah" bersifat dalam sampel, sebab rotasi Procrustes dihitung dari pasangan yang sama dengan yang dievaluasi, dan percobaan ini hanya demonstrasi pada 6 pasangan sintetis, bukan ukuran kinerja CLIP.

7 Pemeriksaan awal bundel

Pemeriksaan awal dilakukan pada 2.072 baris `train.csv` dan 275 baris `val.csv` dari bundel SEA-VL Indonesia, dengan 2.347 berkas di folder `images/`. Setiap baris memiliki berkas gambar, dan tidak ada gambar yang terbagi antara train dan val. Tidak ditemukan duplikat pada kolom `file`, dan tidak ada gambar yang identik secara isi berdasarkan hash MD5. Duplikat caption ditemukan pada 48 baris di train dan 1 baris di val, sedangkan sepuluh caption muncul di kedua split. Setelah caption dinormalisasi dengan huruf kecil dan tanpa tanda baca, jumlah duplikat meningkat menjadi 50 di train dan 1 di val, dengan sepuluh caption yang sama di kedua split. Caption lintas split tersebut umumnya bersifat generik atau berupa nama tempat, misalnya "bromo tengger semeru national park".

Kategori kuliner paling banyak di kedua split, yaitu 792 dari 2.072 baris di train (38%) dan 106 dari 275 baris di val (39%). Dua kategori sangat jarang di train: alat musik hanya 4 baris dan upacara/ritual 18 baris. Alat musik tidak muncul sama sekali di val, dan upacara/ritual hanya 2 baris di val. Kolom lokasi didominasi nilai "Indonesia", yaitu 2.010 dari 2.072 baris di train.

Ada beberapa temuan yang perlu diwaspadai di milestone berikutnya. Sepuluh caption yang sama di train dan val dapat membuat query validasi tampak lebih mudah dari kenyataan, sehingga temuan ini perlu dilaporkan dan sebaiknya dibandingkan dengan Recall yang dihitung tanpa sepuluh pasangan tersebut. Kategori alat musik tidak bisa dievaluasi pada val, dan upacara/ritual hanya memiliki dua query di val, sehingga angka per kategori untuk keduanya tidak stabil dan perlu diberi catatan. Dominasi lokasi "Indonesia" membatasi klaim keterwakilan wilayah di M3. Caption generik yang berulang di train juga perlu dicatat saat menganalisis kegagalan retrieval.

8 Pernyataan integritas

Pernyataan integritas ditandatangani seluruh anggota dan dilampirkan bersama berkas ini (formulir LMS, atau `pernyataan-integritas.docx`).

- ☐ Formulir terlampir dan ditandatangani lima anggota.
- ☐ Nama kelompok dan pembagian peran sudah final (dikunci pada M0).

> **Atribusi data**
> Data: SEA-VL Indonesian subset (`KORIKA-AI/sea-vl_crowdsourcing_id`), diturunkan dari SEACrowd/sea-vl*crowdsourcing, lisensi **CC BY-SA 4.0** (creativecommons.org/licenses/by-sa/4.0). Sitasi: Cahyawijaya et al. (2025),* Crowdsource, Crawl, or Generate? Creating SEA-VL, a Multicultural Vision-Language Dataset for Southeast Asia_, ACL.